

Drug Discovery-AI : Criblage Virtuel & Prédiction d'Activité

Pipeline d'Apprentissage Automatique pour la Classification de l'Inhibition BACE-1 (Alzheimer) et la Régression d'Affinité Kinase (DAVIS)

Abstract

Ce projet applique l'intelligence artificielle et l'apprentissage automatique (Machine Learning) au criblage virtuel, une étape cruciale pour accélérer et réduire les coûts de la découverte de nouveaux médicaments. En combinant la chémo-informatique (RDKit) pour l'extraction de descripteurs moléculaires bidimensionnels et des modèles d'ensemble (Random Forest, Gradient Boosting), le pipeline prédit avec succès :

- L'inhibition binaire de BACE-1 (Classification - Cible pour la maladie d'Alzheimer) avec une justesse de 77,6 % (ROC AUC de 0,851).
- L'affinité de liaison quantitative (Régression - Kinases en oncologie) avec un R^2 de 39,5 %.

Introduction

Criblage Virtuel (Virtual Screening) : L'identification de molécules biologiquement actives parmi des chimiothèques de millions de composés est traditionnellement lente et extrêmement coûteuse en laboratoire (in vitro).

Les cibles thérapeutiques visées :

- BACE-1 (Bêta-sécrétase 1) : Enzyme clé dans la formation des plaques amyloïdes responsables de la maladie d'Alzheimer.
- Kinases (Panel DAVIS) : Protéines régulatrices du cycle cellulaire, cibles majeures dans le traitement des cancers.


La Problématique:

- « Comment prédire de façon fiable, rapide et automatisée l'affinité de liaison et l'activité d'inhibition d'un composé chimique à partir de sa seule structure brute ? »
- « Comment surmonter les défis inhérents aux données biologiques : déséquilibre des classes (BACE) et distributions asymétriques avec des plateaux d'inactivité (DAVIS) ? »

Les Objectifs du Projet:

- Ingénierie de caractéristiques** : Extraire des descripteurs physico-chimiques interprétables à partir des représentations textuelles moléculaires (SMILES).
- Modélisation prédictive** : Entraîner et comparer plusieurs architectures d'apprentissage supervisé (linéaires, SVM, arbres de décision et modèles d'ensemble).
- Aide à la décision** : Identifier le modèle le plus robuste pour guider la sélection des candidats médicaments à synthétiser en priorité.

Méthodologie





Ce schéma illustre le pipeline méthodologique global de notre projet, structuré en six grandes étapes séquentielles. Tout commence par la collecte des jeux de données de référence **DAVIS** et **BACE**, suivis d'une phase de validation chimique des molécules (**SMILES**) via **RDKit**. Ensuite, l'étape de **Feature Engineering** extrait 8 descripteurs physico-chimiques clés pour numériser ces structures. Les données subissent alors un prétraitement rigoureux incluant la standardisation et l'équilibrage par la méthode **SMOTE** pour corriger les disparités de la classification. Une fois nettoyées, les données sont séparées (**80/20**) pour alimenter nos modèles de **Machine Learning** (adaptés aux tâches de classification et de régression), avant d'être évaluées rigoureusement et intégrées au sein d'une application **Streamlit** pour des prédictions en temps réel.

Results

❖ Classification BACE-1 (Alzheimer)


Modèle	Accuracy	Precision	Recall	F1-Score	ROC AUC
Régression Logistique	68.3 %	66.7 %	60.9 %	63.6 %	76.0 %
SVM (Noyau RBF)	74.9 %	71.2 %	75.4 %	73.2 %	81.7 %
Random Forest	75.6 %	74.2 %	71.0 %	72.6 %	84.6 %
Gradient Boosting	77.6 %	73.6 %	79.0 %	76.2 %	85.1 %




Results

❖ Régression DAVIS (Affinité Kinase)

Modèle	MSE	RMSE (nM)	MAE (nM)	R^2 Score
Régression Ridge	1.42×10^7	3767.8 nM	3169.1 nM	9.2 %
SVR (Noyau RBF)	2.13×10^7	4614.5 nM	2378.7 nM	-36.2 %
Random Forest Regressor	1.01×10^7	3182.0 nM	2304.6 nM	35.2 %
Gradient Boosting Regressor	9.46×10^6	3075.8 nM	2304.7 nM	39.5 %



Interface Utilisateur



Conclusion et perspectives

Les résultats montrent que les modèles non-linéaires basés sur des arbres de décision, notamment **Gradient Boosting** et **Random Forest**, sont les plus performants pour capturer la complexité des interactions biologiques à partir de descripteurs moléculaires 2D. La qualité du pipeline de prétraitement (canonicalisation **RDKit**, standardisation et **SMOTE** appliqué uniquement sur l'ensemble d'entraînement) contribue fortement à la robustesse et à la généralisation des modèles sur de nouvelles molécules.

Cependant, plusieurs améliorations sont envisagées pour renforcer les performances du système. Une approche hybride pour le dataset **DAVIS** pourrait combiner classification et régression afin de mieux modéliser les molécules actives. L'intégration de descripteurs 3D et de scores de docking permettrait de mieux représenter les interactions physico-chimiques réelles. Enfin, le passage à des **Graph Neural Networks (GNN)** ouvrirait la voie à des modèles plus puissants capables d'apprendre directement à partir de la structure moléculaire, sans ingénierie manuelle des features.

Technologies utilisées



Encadré par:

- Mr. BENLAHMAR EL HABIB
- Mme GUENDOUL OUMAIMA

Scanner ce code pour
trouver notre projet
sur github:

