



Drug Discovery-AI : Criblage Virtuel & Prédiction d'Activité

Pipeline d'Apprentissage Automatique pour la Classification de l'Inhibition BACE-1 (Alzheimer) et la Régression d'Affinité Kinase (DAVIS)

Abstract

Ce projet applique l'intelligence artificielle et l'apprentissage automatique (Machine Learning) au criblage virtuel, une étape cruciale pour accélérer et réduire les coûts de la découverte de nouveaux médicaments. En combinant la chémo-informatique (RDKit) pour l'extraction de descripteurs moléculaires bidimensionnels et des modèles d'ensemble (Random Forest, Gradient Boosting), le pipeline prédit avec succès :

- L'inhibition binaire de BACE-1 (Classification - Cible pour la maladie d'Alzheimer) avec une justesse de 77,6 % (ROC AUC de 0,851).
- L'affinité de liaison quantitative (Régression - Kinases en oncologie) avec un R^2 de 39,5 %.

Introduction

1. Le Contexte Clinique et Pharmaceutique

Criblage Virtuel (Virtual Screening) : L'identification de molécules biologiquement actives parmi des chimiothèques de millions de composés est traditionnellement lente et extrêmement coûteuse en laboratoire (in vitro).

Les cibles thérapeutiques visées :

- BACE-1 (Bêta-sécrétase 1) : Enzyme clé dans la formation des plaques amyloïdes responsables de la maladie d'Alzheimer.
- Kinases (Panel DAVIS) : Protéines régulatrices du cycle cellulaire, cibles majeures dans le traitement des cancers.


2. La Problématique

- « Comment prédire de façon fiable, rapide et automatisée l'affinité de liaison et l'activité d'inhibition d'un composé chimique à partir de sa seule structure brute ? »
- « Comment surmonter les défis inhérents aux données biologiques : déséquilibre des classes (BACE) et distributions asymétriques avec des plateaux d'inactivité (DAVIS) ? »

3. Les Objectifs du Projet


- Ingénierie de caractéristiques** : Extraire des descripteurs physico-chimiques interprétables à partir des représentations textuelles moléculaires (SMILES).
- Modélisation prédictive** : Entraîner et comparer plusieurs architectures d'apprentissage supervisé (linéaires, SVM, arbres de décision et modèles d'ensemble).
- Aide à la décision** : Identifier le modèle le plus robuste pour guider la sélection des candidats médicaments à synthétiser en priorité.

Pipeline




Réduction de Dimension (PCA) & Équilibrage

La projection ACP 2D, expliquant 76,5 % (BACE) et 76,0 % (DAVIS) de la variance cumulée, révèle un fort chevauchement entre les classes (actif/inactif) et les niveaux d'affinité. Cette structure non linéaire justifie l'utilisation de modèles de machine learning non linéaires, notamment les méthodes basées sur les arbres de décision. Par ailleurs, le dataset BACE présente un déséquilibre des classes. Pour y remédier, la méthode SMOTE a été appliquée uniquement sur le jeu d'entraînement afin de générer des exemples synthétiques de la classe minoritaire, tout en préservant un jeu de test indépendant et non biaisé pour une évaluation fiable.




Technologies utilisées



Results


❖ Classification BACE-1 (Alzheimer)

Modèle	Accuracy	Precision	Recall	F1-Score	ROC AUC
Régression Logistique	68.3 %	66.7 %	60.9 %	63.6 %	76.0 %
SVM (Noyau RBF)	74.9 %	71.2 %	75.4 %	73.2 %	81.7 %
Random Forest	75.6 %	74.2 %	71.0 %	72.6 %	84.6 %
Gradient Boosting	77.6 %	73.6 %	79.0 %	76.2 %	85.1 %



❖ Régression DAVIS (Affinité Kinase)

Modèle	MSE	RMSE (nM)	MAE (nM)	R² Score
Régression Ridge	1.42 x 10 ⁷	3767.8 nM	3169.1 nM	9.2 %
SVR (Noyau RBF)	2.13 x 10 ⁷	4614.5 nM	2378.7 nM	-36.2 %
Random Forest Regressor	1.01 x 10 ⁷	3182.0 nM	2304.6 nM	35.2 %
Gradient Boosting Regressor	9.46 x 10 ⁶	3075.8 nM	2304.7 nM	39.5 %



Conclusion et perspectives

Les résultats montrent que les modèles non-linéaires basés sur des arbres de décision, notamment **Gradient Boosting** et **Random Forest**, sont les plus performants pour capturer la complexité des interactions biologiques à partir de descripteurs moléculaires 2D. La qualité du pipeline de prétraitement (canonicalisation **RDKit**, standardisation et **SMOTE** appliqué uniquement sur l'ensemble d'entraînement) contribue fortement à la robustesse et à la généralisation des modèles sur de nouvelles molécules.

Cependant, plusieurs améliorations sont envisagées pour renforcer les performances du système. Une approche hybride pour le dataset **DAVIS** pourrait combiner classification et régression afin de mieux modéliser les molécules actives. L'intégration de descripteurs 3D et de scores de docking permettrait de mieux représenter les interactions physico-chimiques réelles. Enfin, le passage à des **Graph Neural Networks (GNN)** ouvrirait la voie à des modèles plus puissants capables d'apprendre directement à partir de la structure moléculaire, sans ingénierie manuelle des features.

Travail réalisé par:

- AYAR HANANE
- BENTAIB HAJAR

hananeayar02@gmail.com
hajaar.bentaib@gmail.com

Encadré par:

- Mr. BENLAHMAR EL HABIB
- Mme GUENDOUL OUMAIMA